

THE EXPERIMENTATION PLAYBOOK

统计推断、A/B Testing 与因果推断

A Learning & Interview Guide for
Data Scientist / Applied Scientist

从“统计显著”到“因果识别”，再到“可以上线的产品决策”：一套面向科技行业、兼顾研究深度与项目实践的系统学习手册。

核心知识地图 · 深度应用案例 · 精选教材与论文

8 周核心训练 + 4 周进阶项目 · 面试题与作品集标准

START HERE · ONE-PAGE EXECUTIVE PLAN

怎样使用这份手册

你的统计、优化和交通系统建模基础已经可以支持更深入的训练。下一步不是“再学一遍机器学习”，而是把 **estimand** → **research design** → **estimator** → **uncertainty** → **decision** 形成完整工作链。

设计 明确要改变什么、随机分给谁、成功指标是什么。	识别 解释为什么观察到的差异能对应因果效应。	决策 将效果、风险、成本和不确定性转化为下一步行动。
-------------------------------------	----------------------------------	--------------------------------------

岗位准备优先级

层级	学习范围	面试时展示什么
P0 · 核心	统计推断、Power/MDE、分组、指标设计、SRM、A/A、固定样本实验	从零设计并诊断一次 A/B Test
P1 · 关键	CUPED、聚类标准误、DiD、RDD、IV、Confounding、Interference	说明实验为何可信、何时会失效
P2 · 进阶	CATE、DML、Causal Forest、Switchback、Bandits、Policy Value	复杂系统和个性化干预设计
贯穿始终	SQL、Python、指标口径、可复现报告、产品沟通	可执行代码与一页决策 Memo

给你的个性化建议：把 Transportation / Marketplace 作为主作品集，把 LLM Agent 实验作为研究延伸。前者方便解释供需反馈与干扰；后者适合展示实验协议、测量偏差和多轮模拟稳定性。不要将模拟 Agent 的处理效应直接宣称为真实人群的因果效应。

推荐投入

每周约 **8-10 小时**：精读 3 小时、推导与习题 2 小时、代码实验 3 小时、口头复盘/写作 1-2 小时。前 8 周解决求职核心能力，后 4 周完成一个足够深入、可公开展示的作品集。

使用指南：以下“书籍对应章节”按知识主题标注，避免不同版本章节编号变动；所有 DOI/官网入口见文末“阅读地图与链接”。

NAVIGATION

目录 / 学习地图

- 01 用研究问题驱动统计建模
- 02 Statistical Inference：估计、检验与不确定性
- 03 A/B Testing：从实验设计到诊断与上线
- 04 Causal Inference：不能随机实验时怎么办
- 05 Causal ML 与 Advanced Experimentation
- 06 Product Analytics、SQL 与决策沟通
- 07 进阶应用：Marketplace / Risk / LLM Agents
- 08 书籍路线：买什么、读什么、不必读什么
- 09 8 + 4 周详细学习计划
- 10 作品集项目：从方案到可复现报告
- 11 面试问题与自测标准
- 12 核心公式与统计误区速查
- 13 书籍、论文与官方资源链接

阅读顺序：正在集中投 DS 岗位：02 → 03 → 06 → 04 → 07；准备 Applied Scientist 或方法型岗位：02 → 03 → 04 → 05 → 07。以上顺序是知识依赖路线，而非给具体雇主的岗位难度排名。

01 · QUESTION FIRST

先定义要估计的东西，再选择统计方法

工作中的分析不能从“我会用 t-test、XGBoost 或 DiD”开始。首先写下 **决策问题、目标人群、Treatment、Outcome、时间窗口、Estimand** 和识别假设。

要素	一个配送定价算法的例子
Decision	是否向更多区域推广新配送员定价算法？
Population / Unit	目标城市的区域-时段单元；配送员和订单是观测单元。
Treatment	在指定区域-时段启用新算法；control 运行旧算法。
Primary outcome	每次成功完成配送的净成本（含明确定义的收入/补贴分摊）。
Guardrails	完成率、配送时长、取消率、配送员时薪、异常安全事件。
Estimand	目标市场推广策略下的平均效果；必须说明是否允许跨单元干扰。
Decision rule	主要指标改善达到可接受幅度，同时 guardrail 未出现不可接受退化。

认识四种不同的“效果”

$$ATE = E[Y(1) - Y(0)] \quad ATT = E[Y(1) - Y(0) \mid T = 1]$$

$$ITT = E[Y \mid Z = 1] - E[Y \mid Z = 0] \quad CATE(x) = E[Y(1) - Y(0) \mid X = x]$$

ATE 是总体平均处理效应，**ATT** 是实际接受处理者的平均效应，**ITT** 是“被分配到实验”的影响，**CATE** 是条件在用户特征上的效果。真实产品中，不同 estimand 会对应不同问题；“接受了推荐的用户”不等于“被随机分到新推荐的用户”。

高频错误：随机分配以后，只分析“实际点击/接单/留存”的用户，可能形成处理后选择偏差（post-treatment selection）；主要因果分析通常先保留按原分配的 ITT 视角，再单独讨论依从性与其他 estimand。

掌握标准

给任何产品需求，你能在 5 分钟内写出：一句研究问题、一个 estimand、一个主要指标、两个 guardrails、随机化单位以及最可能破坏识别的机制。

02 · FOUNDATIONS

Statistical Inference：让不确定性进入决策

2.1 从点估计到抽样不确定性

掌握 CLT、Standard Error、Sampling Distribution、Bootstrap、Confidence Interval，并理解“参数的不确定性”和“用户结果的异质性”是两回事。实际业务里，数据量大不自动消除系统偏差；日志错误和选择偏差不会被更多样本自动修复。

$$SE(\hat{p}_T - \hat{p}_C) \approx \sqrt{[\hat{p}_T(1 - \hat{p}_T)/n_T + \hat{p}_C(1 - \hat{p}_C)/n_C]}$$

差值的置信区间需要写明绝对单位。例如转化率从 10.0% 到 10.3%，**绝对变化是 +0.3 个百分点**，相对变化是约 +3%。不要用“上涨 0.3%”混淆两个概念。

2.2 假设检验不等于“发现真理”

- **p-value**：在所设零假设与模型条件成立时，获得至少同样极端结果的概率；不是“零假设为真的概率”。
- **95% CI**：是关于构造程序的长期覆盖率陈述；不是“这个已算出的区间有 95% 的概率包含固定参数”的频率学解释。
- **Power / MDE**：必须在实验前与成本、业务可接受的最小效果、历史方差一起考虑。
- **Practical significance**：即使 p 很小，效果也可能不足以覆盖上线成本；不显著也不意味着证明无效果。

EXERCISE · CONVERSION RATE

假设 $p_0=0.100$ ，想识别 $p_1=0.103$ ，双侧 $\alpha=0.05$ 、Power=0.80、两组人数接近。用二项比例近似公式估算，约需 **每组 15.9 万用户**。这一数字仅说明量级：如存在多次曝光、聚类相关、流量波动或多人共享账户，需重新考虑方差与所需样本。

2.3 深入到面试中的“统计陷阱”

知识点	更深入的实际应用
Bootstrap	偏态收入、复杂 ratio metric；抽样单位要与独立性结构匹配，cluster bootstrap 不能错做 row bootstrap。
Multiple testing	多个 primary metrics、上百个 subgroup；预先定义 primary family，区分 FWER 与 FDR。
Heteroskedasticity	不同用户消费方差差异大；选稳健标准误或明确方差模型。
Cluster dependence	司机多次接单、同用户多订单；用用户/司机/区域等恰当聚类，不能把订单数当作独立用户数。
Heavy tails	收入和单量可能长尾；讨论 Winsorization 的事前规则、robust 方法与业务解释。

知识点	更深入的实际应用
Missingness	退订或未触发事件导致缺失；判断 MCAR / MAR / MNAR 与处理影响测量概率的可能。

2.4 一道更接近 Applied Scientist 的追问

同一个用户产生 20 条订单，为什么不能把 20 条订单当作 20 名独立用户？因为处理分配、历史偏好和行为冲击可能在用户内相关。独立单位的有效数量与行数不同：你需要从数据生成过程推导 Standard Error，而不是先套用普通 t-test。

MINI LAB · FALSE POSITIVE UNDER CLUSTERING

生成 1,000 个司机、每人 10–30 单数据，引入司机层面的随机效应。对完全无 treatment effect 的模拟实验，分别采用“订单独立”与“司机聚类”的分析，重复 1,000 次，报告名义 $\alpha=0.05$ 下的实际假阳性比例。这项模拟能直观解释 unit-of-analysis error。

推荐书： [B2] Practical Statistics 第 2 版或更新的第 3 版，集中读 Sampling、Statistical Experiments、Regression； [B5] All of Statistics 的 Bootstrap、Hypothesis Testing、Regression、Statistical Decision Theory 用于理论补足。

03 · INDUSTRY CORE

A/B Testing：完整设计、分析与诊断

3.1 实验前：五件事必须写下来

1. **产品机制与指标树**：为什么 treatment 有可能改变 primary metric？是否存在短期提高、长期伤害？
2. **Randomization unit**：用户、设备、订单、配送员、商家、城市或区域-时段？与分析单位不一致时如何估计方差？
3. **Exposure / triggering**：哪些人真正有机会受 treatment 影响？避免根据处理后的行为筛选样本而引入偏差。
4. **Power / duration**：基线转化率、MDE、历史方差、业务周期、流量、聚类设计效应和可能流失率。
5. **Pre-registered analysis**：主要指标、guardrails、子组、缺失处理、异常排除、停止规则、上线门槛。

3.2 实验中：先查可信度，再看显著性

SRM / 分组偏差

预设 50/50，实际分组若系统性偏离，检查流量路由、日志丢失、device merge、bot 过滤、eligible population 变化。SRM 不是简单的“产品无效”。

A/A Test

两组运行同一体验，检查实验平台、方差估计、p-value 分布、metric pipeline。它并非保证未来 A/B 必然有效。

Peeking

固定样本检验不能每天看到显著就提前停止；需预设 group-sequential 或 always-valid 分析方法。

Guardrails

主指标改善，也可能伴随取消率上升或用户伤害；上线建议必须同时展示 primary + guardrails。

3.3 CUPED：为什么可以减少方差

使用 **实验发生前**的协变量 X 对结果 Y 做调整：实验组与对照组在期望上仍可比，同时消除用户历史水平引起的部分噪声。[P1]

$$Y_{\text{adj}} = Y - \theta(X - E[X]) \quad \theta^* = \text{Cov}(Y, X) / \text{Var}(X)$$

在简单线性条件下，X 与 Y 的相关性越强，潜在方差收益越大。实践中要注意协变量不能受 treatment 影响，且调整过程、适用样本及方差估计要与实验协议一致。

REAL-WORLD APPLICATION • SUBSCRIPTION PRODUCT

要检测会员续费率的小幅提升：先用历史活跃度或实验前消费构建 CUPED 协变量，比较 raw vs adjusted 的点估计、置信区间宽度、SRM 和子组稳定性。单纯看到 p-value 更小，不足以证明处理正确；应检查协变量的时间先后关系。

3.4 Ratio metrics、长期效应与异质性

“每用户收入”与“每订单收入”回答的问题不同。对于总收入/总订单一类 ratio metric，分子分母通常相关，需按适当实验单位估计不确定性（例如 delta method、cluster bootstrap）。长期指标还需要考虑新鲜感、学习效应和留存延迟。

上线前的典型误判：以订单为随机化单位，却把一个司机的多次订单当独立观测；或在明显相互竞争的市场中把 A/B 估计解释为全市场推广效果。

3.5 上线报告的审阅顺序

先问	再看
实验有效吗？	assignment、曝光、SRM、日志、实验期间产品变更和 A/A。
识别的是什么？	target population、ITT、触发条件、分母与聚类。
不确定性呢？	CI、预设 MDE、multiple testing、停止规则。
可不可以推广？	guardrails、长期留存、异质性、市场干扰与上线成本。

基础精读：[B1] Trustworthy Online Controlled Experiments 的 End-to-End、Metrics、Statistics、Variance Estimation、A/A、SRM、Leakage & Interference、Long-Term Effects；连续监控方法补读 [P3]。

04 · WHEN RANDOMIZATION IS NOT AVAILABLE

Causal Inference: 先识别，再估计

当政策、价格或风险管理方案无法随机投放时，回归系数本身不是因果效应。必须先解释：“如果没有 intervention，这组人的结果会如何？”

4.1 核心框架

$$\text{Observed } Y = T \cdot Y(1) + (1 - T) \cdot Y(0)$$

反事实不可同时观察。随机化通过设计使组间可比；观察数据只能依赖更明确的结构与假设，例如 conditional exchangeability、positivity 与 consistency。DAG 用来识别潜在混杂因素、媒介变量和 collider，避免把处理后的变量随意加进回归。

方法	什么时候考虑	必须追问的条件/陷阱
Regression / PS	已测量足够的处理前混杂因素，处理组与对照组有共同支持。	遗漏混杂、overlap、极端权重；matching 不自动创造可忽略性。
DiD	部分地区/组织在不同时间推出政策，有可信的比较组。	反事实平行趋势、预期效应、共同冲击、差异化时间趋势；错位实施时需现代 estimators。
RDD	阈值/分数决定 treatment 的可获得性。	阈值附近可比、分数是否可操纵、带宽/函数形状、只识别局部效果。
IV	有外生的 treatment 变动来源，处理自身存在内生性。	相关性、排除限制、独立性；若解释为 LATE 还需要合适的单调性等条件。
Synthetic Control	少量城市/市场受到政策冲击，拥有足够长的处理前时间序列。	donor pool、pre-fit、同期溢出、结果是否被其他政策共同驱动。

4.2 DiD 的具体例子：城市交通收费

城市 A 新增收费，而若干其他城市未变。你可以比较政策前后两组的拥堵变化：

$$\text{DiD} = (\bar{Y}_{A,\text{post}} - \bar{Y}_{A,\text{pre}}) - (\bar{Y}_{C,\text{post}} - \bar{Y}_{C,\text{pre}})$$

仅有这个差分计算还不够：研究设计还要展示处理前趋势、其他同期事件、交通转移造成的跨地区溢出，以及政策宣布后但实施前的行为变化。若多个城市错位实施，传统 two-way fixed effects 可能混合不同时间和组别的处理效应，不宜直接假设一个系数就是目标 ATE。

INTERVIEW FOLLOW-UP · WHAT IF PRE-TRENDS DIFFER?

不要只说“再加更多 control variables”。应先重新评估比较组与 estimand，考虑更合适的配对、趋势模型或替代设计；在不可辩护时，诚实地把结果降格为描述性分析。

4.3 面试中需要主动呈现的稳健性

- 可视化处理前 outcome 与 baseline covariate 的可比性；
- 报告 overlap、标准化差异以及对极端权重的敏感性；
- 提供安慰剂结果、伪处理时间和不同带宽/模型规格；
- 明确效应对人群、时间和市场的外推边界；
- 谨慎区分 “no evidence of effect” 和 “evidence of no practically important effect”。

4.4 把识别假设写成可以被质疑的句子

一份成熟的因果分析，应在结论前单列 “哪些假设不能由数据直接证明”。例如：DiD 的反事实平行趋势不能只用政策前检验来证明；RDD 的局部识别不等于全市场效果；IV 的排除限制通常无法只靠相关性统计得到保证。

MINI LAB · SAME DATA, DIFFERENT CLAIMS

在一份模拟城市面板里构造共同冲击、城市特定趋势与跨城市溢出。比较朴素前后差、简单 DiD 和加入合适设计诊断后的结论，给每种结果写一条 “不允许外推” 的限制说明。

推荐学习次序： [B4] The Effect 先建立 research design 直觉；[B3] The Mixtape 深入 DiD/RDD/IV/SC；[B7] What If 用于识别假设、纵向因果推断的进阶讨论；Python 随练可使用 [B8]。

05 · APPLIED SCIENTIST EXTENSIONS

Advanced Experimentation 与 Causal ML

5.1 Heterogeneous Treatment Effects: 谁受益?

ATE 可能接近零，却掩盖强烈的群体差异。CATE(x) 用于预测特征 x 的目标单位在 treatment 下的平均效应。但对 Y 的预测好 不等于 对 treatment effect 的估计可靠。

方法	需要理解的重点
S/T/X-learners	不同建模方式在组间样本不均、处理效应复杂度和模型误差上的权衡。
Double ML	使用 outcome / treatment nuisance models、cross-fitting 与 orthogonalization 控制一阶估计误差。
Causal Forest	利用 covariates 探索异质性；honest splitting、覆盖区间与随机误差不应被忽略。
Uplift / Policy Learning	按预期增量收益和施策成本优化分配，而不是给最高预测风险者一律施策。
Bandits	在探索与利用中动态分配；适应性数据和离线评估需特别设计，不能直接沿用普通 fixed-horizon p-value。

DML intuition: $\tilde{Y} = Y - \hat{m}(X)$, $\tilde{T} = T - \hat{e}(X)$, then estimate effect from $\tilde{Y}$ vs $\tilde{T}$

上式仅是 partialling-out 的概念示意，具体目标、正交得分和标准误要按估计量定义。EconML 提供 DML、CausalForestDML、DRLearner 等实现 [T1]；使用软件不能替代因果识别条件。

5.2 Marketplace: 普通 A/B Test 为什么可能错

配送员和订单共享供需池：给一部分订单新调度算法，可能影响另一部分旧算法订单。这是 **interference**，会让常规个体级 estimand 难以代表全市场推广效果。

Cluster randomization

按相对独立的市场/区域分组随机化。检查区域边界溢出与有效 cluster 数，按 cluster 层面处理方差。

Switchback

区域在随机选定时间窗轮流运行旧/新算法，评估时间趋势、washout、carryover、自相关与时间窗长度。

DoorDash 的工程案例描述了区域-时间随机化 [P2]；Airbnb 的定价 meta-experiment 展示了 marketplace interference 与 cluster randomization 的关系 [P4]。这两个材料尤其契合你的交通系统建模经验。

5.3 进阶的正确顺序

先能做好普通 ITT、SRM、Power 和标准误，再学 CATE/多臂试验。否则复杂模型只会让不可信的结论变得更难发现。

5.4 更深一层：从 CATE 到最优投放

不是把 treatment 分给 CATE 最高的用户就能得到最优业务政策。还要减去干预成本，并约束预算、库存、用户权益与市场干扰。若一项激励影响用户之间的行为，逐人预测 CATE 后直接排序也可能失效：总体价值不一定等于孤立个体增量的简单加总。

Policy value (intuition) = $E[\text{incremental outcome under policy} - \text{intervention cost}]$

MINI LAB · POLICY LEARNING

先用随机模拟数据拟合 CATE，在独立测试样本或新的随机试验中评估基于 CATE 的 targeting rule；再增加预算约束和干扰机制，检查离线收益的乐观偏差。必须区分“发现异质性”与“证明一项 targeting 策略有效”。

06 · PRODUCT & EXECUTION

Product Analytics、SQL 与实验决策

6.1 指标不是越多越好，而是有清晰因果链

Product change → User/market behavior → Metric movement → Business outcome

例如推荐算法优化点击率，可能降低长期满意度；减少配送时间，也可能依赖不可持续的配送员激励。必须设计 **primary metric + diagnostic metrics + guardrails**，并明确指标口径、归因窗口、去重和时区。

场景	Primary metric 示例	Guardrails / 深挖项
推荐系统	每 eligible user 的有效消费/成功交易	长期留存、投诉、冷启动、feed 多样性
配送市场	净成本/成功履约、完成率	延时、司机收益、取消、区域不公平
风险模型	在既定业务规则下的净价值	错误拒绝、覆盖率、漂移、合规与公平性
LLM 决策工具	明确标注条件下的任务完成质量	事实性、偏差、重测稳定性、人类审查成本

6.2 SQL / 数据完整性：需要能独立做的事

- 构建实验 assignment、exposure、event、outcome 的可复用数据模型；
- 用 SQL 检查用户唯一性、分组互斥、时间先后、join duplication；
- 处理事件级 → 用户级/cluster 级 aggregation，标记实验生效前和后；
- 制作 metric dictionary，并保留代码版本、样本选择、排除规则。

6.3 面向 PM 的一页决策 Memo

结构：（1）我们改变了什么；（2）可信度：随机化、SRM、数据完整性；（3）估计的 effect 和 CI；（4）guardrail；（5）对未观测风险的限制；（6）上线 / 继续实验 / 暂停 / 细分投放的条件性建议。一定区分统计结论和业务判断。

配套书：[B6] Designing with Data。它偏产品问题定义与 UX 解释，不代替严谨统计教材；你的目标是用它练习“产品语言 → estimand/metric/experiment → 决策语言”的转换。

07 · DOMAIN APPLICATIONS

三个适合你深入练习的应用场景

CASE A · TWO-SIDED TRANSPORTATION MARKETPLACE

问题：新 Dispatch / Courier Pricing 算法是否改善履约？

设计：先对比订单级随机化与区域-时段 Switchback 的 estimand；模拟司机共享、订单溢出、供需冲击。
Primary = 每成功订单净成本或完成率，Guardrails = 配送员有效时薪、取消率、延迟尾部。

进阶分析：设定 carryover 时长；按时间窗聚类/阻断；展示 naïve order-level 与正确实验分析的偏差差异；讨论假日、天气及相邻区域溢出。

简历价值：端到端实验设计 + 系统建模 + 因果估计，展示你和纯通用机器学习项目不同的专业积累。

CASE B · CREDIT / EVICTION RISK MODEL DEPLOYMENT

问题：新预测模型究竟提高了预测指标，还是改善了决策结果？

先区分：离线 KS/AUC/Lift 衡量预测或排序，不能单独证明模型上线导致业务结果改善。业务策略改变后，谁收到干预、谁的结果可观测，可能会发生选择偏差。

设计：在具备授权与适当合规审查的前提下，设定策略级 randomized evaluation 或审慎的准实验；分析成本、覆盖和误差影响。作品集只使用公开数据或自行构造的模拟数据，不使用实习的非公开记录。

进阶分析：policy value、selective labels、distribution shift、uncertainty 与人群差异；切勿把“风险分数更准”写成“已证明减少驱逐”。

CASE C · LLM AGENTS FOR POLICY FEEDBACK

问题：信息、Prompt 或候选政策菜单是否改变 Agent 回答？

设计：固定模型版本、temperature、候选政策和初始条件；因子实验：Information × Prompt × Menu × Model。明确随机化单元是生成调用、Agent identity 还是 community；如果反复使用同一 profile，分析时纳入 profile 的重复测量。

结果：偏好排名变化、rank correlation、entropy、retest agreement、真实调查基准（若存在）下的校准误差。对多次生成与多个指标预设主要检验，避免看完结果再挑选稳定性最好的一组。

重要边界：可以识别“实验设置对模拟回答的影响”，但若没有可靠外部验证，不可推论为“真实居民的偏好被改变”。

08 · CURATED READING

书籍阅读路线：精读三本，按需查阅四本

目标不是每本从头读到尾，而是让每周任务都能映射到书籍章节、代码和可交付成果。以下书目及版本已按 2026 年 9 月可核对的信息整理。

[B1] Trustworthy Online Controlled Experiments

Ron Kohavi, Diane Tang, Ya Xu · Cambridge University Press · 2020 · 主线教材

精读：End-to-End Experiment、OEC/Metrics、Statistics、Variance Estimation、A/A、SRM、Interference、Long-Term Effects。

产出：一份包含分组方案、MDE、指标树、SRM 和 Go/No-Go 的实验协议。

[Cambridge 官网](#) / [目录](#)

[B2] Practical Statistics for Data Scientists（第 2 版）或新版 AI-Assisted Statistics for Data Scientists（第 3 版）

Peter Bruce, Andrew Bruce, Peter Gedeck · O' Reilly · 2020 / 2026 · 基础复习与 Python

精读：Sampling Distributions、Statistical Experiments & Significance、Regression。第三版于 2026 年 6 月出版，并增加 AI 内容；若重点是统计面试，第 2 版仍足够且篇幅更精简。

产出：Python 从零实现 proportion test、bootstrap CI、power analysis。

[第 2 版](#) | [第 3 版](#) | [第 3 版代码](#)

[B3] Causal Inference: The Mixtape

Scott Cunningham · Yale University Press · 主线因果识别教材 / 免费在线版

精读：Potential Outcomes、DAG、Matching、RDD、IV、DiD、Synthetic Control。

产出：以城市政策为例完成 DiD + pre-trend / placebo 诊断。

[作者官网](#) | [第一版在线内容入口](#)

[B4] The Effect: An Introduction to Research Design and Causality

Nick Huntington-Klein · 第 2 版 2025 · 研究设计直觉

精读：因果问题、识别设计、观察数据、DiD/IV/RDD 对应思路。

产出：为同一业务问题比较两个可行设计及其识别限制。

[免费在线版](#) | [第 2 版出版社页面](#)

[B5] All of Statistics: A Concise Course in Statistical Inference

Larry Wasserman · Springer · 2004 · 数理统计查漏补缺

重点查阅：Bootstrap、Parametric Inference、Hypothesis Testing、Statistical Decision Theory、Regression。

产出：解释某个统计量的估计假设、误差来源和渐近近似。

Springer

[B6] Designing with Data: Improving the User Experience with A/B Testing

Rochelle King, Elizabeth F. Churchill, Caitlin Tan · O' Reilly · 2017 · 产品语言

重点查阅：问题定义、数据与设计、可测试假设、指标和决策沟通。

产出：把一项模糊产品需求写成 1 页 Experiment Brief。

O' Reilly

[B7] Causal Inference: What If / [B8] Causal Inference for the Brave and True

Miguel Hernán & James Robins / Matheus Facure · 免费进阶 / Python 配套

[B7]：在需要更严格的识别假设、g-methods 和纵向因果推断时查阅。**[B8]：**跟做 Python Notebook；部分进阶章节仍在持续完善。

What If 官网 | Brave and True 在线书

不必一次买齐：优先 B1 + B2（任选版）+ B3；B4/B7/B8 有在线学习入口，B5 适合作为遇到证明和统计性质疑问时的“参考工具书”。

09 · PRACTICE SCHEDULE

8 周核心学习 + 4 周进阶作品集

每周约 8–10 小时。每个阶段包含四件事：**读**（书/论文）、**推**（概念/公式）、**写**（Python/SQL）、**讲**（3 分钟口述研究结论）。

周	学习重点	读什么	必须交付
W1	Estimand、CLT、CI、Bootstrap、两比例检验	B2 Sampling + Significance; B5 查漏	Notebook: CI、bootstrap、绝对/相对 lift; 2 页推导笔记
W2	Power、MDE、Multiple testing、聚类相关	B2 Experiments; B1 Statistics	样本量计算器 + 模拟 Type I error / Power
W3	Randomization、OEC、primary/guardrails、ITT	B1 End-to-End + Metrics; B6	完整 Experiment Brief + SQL metric dictionary
W4	SRM、A/A、CUPED、peeking、ratio metric	B1 Advanced Analysis; P1/P3	诊断型 Notebook: 故障注入、方差压缩、异常报告
W5	Potential outcomes、DAG、selection bias、PS	B4; B3 基础章节	画 DAG + 构建 observational study protocol
W6	DiD、event study、staggered adoption 注意点	B3 DiD; B8 Python	模拟政策评估 + pre-trend / placebo / sensitivity
W7	RDD、IV、Synthetic Control, 识别范围	B3 相关主题; B4 对照	方法比较表: 同一问题如何选择研究设计
W8	综合实验 Case + 产品沟通 + 模拟面试	回顾 B1/B2/B3	一页决策 Memo + 15 分钟技术讲解
W9	HTE、CATE、S/T-learner、DML	B8 进阶; T1 EconML	同一模拟数据比较 ATE 与 CATE 估计
W10	Marketplace interference、cluster、switchback	P2 DoorDash; P4 Airbnb	模拟 order-level vs region-time 设计并对比偏差
W11	作品集整合: 指标管道、稳健性、可视化	根据项目回查书籍	可复现 GitHub repo + figures + README
W12	Method defense、业务陈述、Mock Interview	口述复盘笔记	8–12 页技术报告 + 1 页 memo + 3 条简历 bullet 候选

建议的每周复盘模板

四个问题：（1）本周核心 estimand 是什么？（2）为什么选这个 design/estimator？（3）什么情况会让估计不可信？（4）如果 PM 只给你一分钟，你会如何解释结果和限制？

如果集中申请窗口提前到来：优先完成 W1–W4、W8、W10。需要应对偏研究型 Applied Scientist：再重点完成 W5–W7、W9 和 W11–W12。

10 · PORTFOLIO BLUEPRINT

作品集模板：一个可复现的 Marketplace Experiment

项目标题

Designing Trustworthy Experiments under Marketplace Interference: A Dispatch Algorithm Case Study

1. 公开透明的数据来源

使用自行生成的区域-时段-司机-订单数据。建立可控制的模拟机制：供需比、司机共享、天气/时段趋势、处理效果、不同区域之间的跨界流动、处理残留。公开模拟参数和随机数种子；注明这是方法演示，不是某平台真实部署结果。

2. 至少比较三种设计

Design	估计目标与诊断
Naïve order-level A/B	在互相影响的订单间随机化，说明为什么全市场效果可能被污染。
Market / region cluster	按区域随机化；比较组内相关、有效 cluster 数和边界泄漏。
Region × time switchback	按区域-时段随机化；设置 washout，检查 carryover、时段与区域固定差异。

3. 规定五组必须展示的结果

1. **设计质量**：assignment 演示、均衡检验、SRM、A/A。
2. **主要指标**：ATE/ITT、绝对效果、相对变化、CI、原始与调整后估计。
3. **敏感性**：不同处理强度、跨区溢出强度、cluster 大小与窗口长度。
4. **业务约束**：成本、履约成功率、司机收入、公平性 guardrail。
5. **决策**：什么情况下扩大试验，什么情况下保留旧算法，什么需要额外验证。

4. 最终仓库建议

```
/README.md /experiment_protocol.md /data_generator.py
/analysis_ab.ipynb /analysis_switchback.ipynb /analysis_causal.ipynb
/figures/ /reports/technical_report.pdf /reports/decision_memo.pdf
```

展示原则： README 首屏写研究问题、三种设计、两幅核心图与结论限制；不要把重点埋在代码后。可补充 SQL 建表与 metric query，体现接近真实团队的数据分析流程。

5. 项目完成时的审计清单

检查项	达成标准
可复现	别人根据 README 可建立环境、生成数据、重跑分析和图表。
机制清楚	设定 effect、noise、cluster correlation、spillover、carryover 各自可控。
负结果透明	至少展示一组方法无明显改善、或假设被严重破坏时的失败案例。
统计与业务分离	技术报告谈 estimand/CI/敏感性，memo 谈上线条件、成本、guardrails。
面试可讲	准备 90 秒概要、5 分钟机制说明及 15 分钟方法质疑回答。

6. 可直接用于技术面试的讲解顺序

用一张图展示共享配送员造成的 interference；用第二张图展示三种随机化策略；再用结果图显示真实模拟效应和三种估计偏差。最后不强调“哪个算法显著”，而是强调“什么时候能相信这个实验，不能相信时如何重新设计”。

实验结果的诚实表述：“在设定的干扰机制下，cluster/switchback 设计比 naïve randomization 更接近设定的真实效果”，比“我证明了 Uber 应该使用某算法”更可信。

11 · INTERVIEW READINESS

面试题：回答时必须覆盖的分析结构

典型问题	回答要点
1. Conversion 10.0% → 10.3%，能上线吗？	单位、分母、MDE、power、CI、guardrails、数据质量、业务成本。
2. 为什么大样本的 p-value 很小也可能不重要？	effect size 与 ROI；置信区间和最小有意义效果。
3. 实验提前结束会怎样？	fixed-horizon peeking；预设 sequential testing。
4. 实验 50/50 结果出现 54/46？	SRM 检验，追查 assignment/exposure/logging/filtering。
5. 订单随机化为何可能有问题？	一个司机服务多单、市场供需干扰、cluster/switchback。
6. CUPED 为什么有效？	处理前协变量与 outcome 相关；协变量不可被 treatment 影响。
7. 如何决定实验运行多久？	MDE、α、power、历史方差、流量、业务周期、依赖结构。
8. 如果 treatment 增加订单但降低 retention？	primary + guardrails、长期效应、业务约束。
9. 没法 A/B Test 怎么评估城市政策？	反事实、可用比较组、DiD/SC、parallel trends、spillover。
10. DiD 的 pre-trend 不平行怎么办？	重估 research design、可比性、敏感性、边界诚实陈述。
11. 什么情况下 IV 不可信？	排除限制、外生性、weak instrument、局部效应。
12. 风险模型 AUC 更高是否证明业务更好？	预测质量不等于决策因果效果；选择性结果与政策价值。
13. 你会如何找到最受益的用户？	CATE/HTE、样本切分、policy value、组间公平性和稳健性。
14. 模拟 LLM Agent 的实验结论能外推真实居民吗？	需外部基准与验证，明确模拟处理效果不等于人类因果效应。

每题用统一的 6 步结构回答

Question → Estimand → Design → Data/Diagnostics → Estimation/Uncertainty → Decision & Limits。如果面试时间紧，先说关键假设和决策变量，再展开统计方法；不是先背公式。

4 级掌握标准（自评而非岗位评分）

- 1

能定义术语
- 2

能举场景并推导
- 3

能实现并诊断
- 4

能在限制下做出可解释的决策建议。

12 · QUICK REFERENCE

公式、概念与常见误区速查

概念	关键表达 / 判断
两比例差值 SE	$\sqrt{[\hat{p}_T(1-\hat{p}_T)/n_T + \hat{p}_C(1-\hat{p}_C)/n_C]}$
近似样本量 (等组)	$n/arm \approx 2(z_{1-\alpha/2} + z_{1-\beta})^2 p(1-p)/\delta^2$; 独立 Bernoulli 近似, 非万能公式。
Relative lift	$(\hat{p}_T - \hat{p}_C) / \hat{p}_C$; 必须与绝对效果一起报告。
Cluster design effect	简单同质等规模近似: $1 + (m-1)\rho$; m =cluster 平均大小, ρ =ICC。
CUPED	$Y_{adj} = Y - \theta(X - E[X])$; X 必须是处理前的合适协变量。
DiD	处理组前后差 - 对照组前后差; 识别离不开可信的平行趋势等假设。
ITT vs per-protocol	分配效应 $\neq$ 实际接受 treatment 的简单条件均值差。
Multiple testing	FWER 控制至少一次假阳性; FDR 控制拒绝集合内的期望错误比例。
Interference	Y_i 可能取决于其他单位的 treatment; 常规个体 SUTVA 不成立。
Statistical vs practical	p-value、CI、effect size、可接受业务阈值与执行成本共同决定结论。

注意：公式是复习提示，不替代推断条件、设计效应、有限样本修正和真实系统中的敏感性分析。尤其不要对有明显网络干扰和自相关的订单级数据直接套用独立样本公式。

13 · VERIFIED RESOURCES

核心论文、官方文档与进一步阅读

与书籍互补的免费或可访问资源；以下列出作者/出版方入口以便核对版本、代码或论文。部分出版社全文可能需要学校图书馆权限。

[P1] CUPED 的原始论文

Alex Deng, Ya Xu, Ron Kohavi, Toby Walker (2013). Improving the Sensitivity of Online Controlled Experiments by Utilizing Pre-Experiment Data. WSDM. DOI: 10.1145/2433396.2433413
<https://doi.org/10.1145/2433396.2433413>

[P2] DoorDash Switchback Experiments

David Kastelman, Raghav Ramesh (2018). Switchback Tests and Randomized Experimentation Under Network Effects at DoorDash.
[官方工程博客](#)

[P3] Sequential testing 与提前查看数据

Statsig 官方文档: Frequentist Sequential Testing. 结合 fixed-horizon inference 理解为什么要调整停止规则。
[官方技术说明](#)

[P4] Airbnb Marketplace Interference

Reducing Interference Bias in Online Marketplace Experiments Using Cluster Randomization: Evidence from a Pricing Meta-experiment on Airbnb. Management Science, online 2024.
[论文 DOI / INFORMS](#)

[T1] EconML 方法与代码

Microsoft Research / PyWhy 的 EconML 项目文档: DML、CausalForestDML、DR learners、meta-learners 等。
[EconML 官方文档](#) | [代码仓库](#)

你现在就可以开始：今天先定一个真实业务问题，用第 1 节的七行模板写出 estimand 和设计；接着按 W1 用 Python 实现两比例差、CI 和 power。完成这三步后再去读高级 CATE 或 causal forest，学习效率会高得多。

资料核对时间：2026 年 9 月。本文面向职业学习；模拟案例与估算属于教学示范，非平台真实业绩或雇主内部实验结论。